

Projet de data science appliquée

Documents autorisés : documentation officielle des outils uniquement

Les deux sujets s'appuient sur le fichier `titanic_dataset.csv` utilisé en cours (891 passagers, 12 colonnes). L'usage d'un assistant d'intelligence artificielle, d'un générateur de code ou de texte est interdit pour la réalisation du projet. Chaque étudiant traite un seul sujet, attribué par l'enseignant. Les rendus sont suivis d'un entretien oral de dix minutes au cours duquel l'étudiant explique ses choix.

Sujet A. Application Streamlit : le Titanic vu par les familles

Rendu : le fichier `app.py`, exécutable avec `streamlit run app.py`, accompagné d'un fichier `README.md` d'une page au plus et d'une capture d'écran par onglet.

Point de départ : le tableau de bord réalisé en cours (filtres de la barre latérale, indicateurs, onglets Survie, Démographie et Données brutes). Vous le prolongez ; il n'est pas demandé de le refaire.

Le tableau de bord du cours répond à la question « qui a survécu ? » par sexe, par classe et par âge. Il laisse de côté une information que la base contient : les familles. Les colonnes `SibSp` (frères, sœurs et conjoints à bord) et `Parch` (parents et enfants à bord) permettent de reconstituer la taille de la famille de chaque passager, et le nom contient un titre (Mr, Mrs, Miss, Master, etc.). On vous demande de compléter l'application pour qu'un utilisateur non technicien puisse répondre à la question suivante : voyager en famille augmentait-il les chances de survie ?

1. Préparation des données (6 points)

1. Dans la fonction de chargement, créer la colonne `taille_famille` égale à `SibSp + Parch + 1`, puis la colonne `type_famille` prenant trois valeurs : « Seul » (taille 1), « Petite famille » (2 à 4), « Grande famille » (5 et plus).
2. Extraire le titre de la colonne `Name` (le mot situé entre la virgule et le point). Regrouper les titres rares : Mlle et Ms sont assimilés à Miss, Mme à Mrs ; tout titre autre que Mr, Mrs, Miss et Master est classé « Autre ».
3. Remplacer les âges manquants par la médiane d'âge du titre correspondant. Conserver une colonne `age_impute` (vrai ou faux) indiquant les lignes modifiées.
4. Indiquer dans le README le nombre d'âges imputés et expliquer, en deux ou trois phrases, pourquoi la médiane par titre est préférable à la médiane de l'ensemble des passagers.

2. Nouvel onglet « Familles » (9 points)

1. Un graphique en barres du taux de survie par type de famille, pourcentages affichés sur les barres, axe vertical de 0 à 100 %.
2. Le même taux de survie par type de famille, ventilé par sexe (barres groupées), avec la palette et l'ordre des modalités définis dans le tableau de bord du cours.
3. Un tableau croisé affiché avec `st.dataframe` : type de famille en lignes, classe en colonnes, nombre de passagers en valeurs, avec une ligne et une colonne de totaux.

4. Un filtre « Type de famille » dans la barre latérale (sélection multiple, tout coché par défaut), agissant sur tous les onglets, y compris ceux du cours. L'application ne doit pas produire d'erreur lorsque la sélection est vide.
5. Deux indicateurs en tête d'onglet : le nombre de passagers voyageant seuls et le taux de survie des grandes familles, chacun accompagné de l'écart par rapport à l'ensemble de la base.

3. Interprétation (5 points)

1. Sous les graphiques, un texte de cinq à huit lignes répondant à la question posée, en s'appuyant sur des chiffres lus dans vos propres graphiques. Vous devez y examiner au moins une explication concurrente : par exemple, les grandes familles voyagent-elles surtout en troisième classe ? Est-ce le type de famille ou la classe qui explique la survie ?
2. Une section repliable « Limites des données » indiquant l'effectif des grandes familles, la part des âges imputés et ce que le jeu de données ne permet pas de conclure.

Il est attendu que l'application se lance sans erreur, que les agrégations passent par une fonction (comme `taux_par` en cours) plutôt que par des calculs répétés, que les graphiques portent un titre et des unités, et que chaque pourcentage cité dans le texte soit accompagné de l'effectif correspondant.

Sujet B. Rapport Power BI : tableau de bord du Titanic

Rendu : un fichier .pbix et une page de notes de conception (format libre).

Point de départ : le fichier `titanic_dataset.csv`. Il s'agit de reproduire, puis de compléter, ce que le tableau de bord Streamlit du cours affiche, avec les moyens propres à Power BI : Power Query pour la préparation, DAX pour les mesures, interactions entre visuels pour l'exploration.

1. Préparation dans Power Query (6 points)

1. Importer le fichier et typer correctement chaque colonne (Age et Fare en nombre décimal, Survived et Pclass en nombre entier, le reste en texte).
2. Remplacer les codes par des libellés : Sex en Homme / Femme ; Survived en Survivant / Décédé ; Pclass en 1ère, 2ème, 3ème classe ; Embarked en Cherbourg, Queenstown, Southampton, les valeurs manquantes devenant « Inconnu ».
3. Créer la colonne `Taille famille` (`SibSp + Parch + 1`) et la colonne `Type famille` (Seul, Petite famille, Grande famille, avec les mêmes seuils que le sujet A).
4. Extraire le `Titre` de la colonne `Name` avec les outils de l'éditeur de requêtes et regrouper les titres rares comme au sujet A. Cette étape se fait entièrement dans Power Query, sans colonne calculée DAX.
5. Créer une table de dimension `Classe` (clé, libellé, ordre de tri) reliée à la table des passagers, de sorte que les classes apparaissent dans l'ordre 1ère, 2ème, 3ème dans tous les visuels.

2. Mesures DAX (6 points)

Créer une table de mesures contenant au minimum :

Mesure	Définition
Nb passagers	nombre de lignes
Nb survivants	passagers dont le statut est Survivant
Taux de survie	survivants divisés par passagers, en pourcentage, sans erreur lorsque le dénominateur est nul
Taux de survie global	le même taux, insensible aux filtres appliqués dans le rapport
Écart vs global	différence entre les deux taux précédents, en points de pourcentage
Âge moyen renseigné	moyenne des âges non vides ; les âges manquants ne doivent pas être comptés comme zéro
Part des âges inconnus	lignes sans âge rapportées au total des lignes

Expliquer dans les notes de conception, en quelques lignes, pourquoi la mesure « Taux de survie global » ne varie pas lorsqu'on filtre, et à quoi elle sert dans un rapport.

3. Le rapport (8 points)

Page 1, Survie. Une ligne de cartes (passagers, taux de survie, écart vs global, âge moyen). Un graphique du taux de survie par sexe, un par classe, et un graphique groupé classe et sexe. Des segments sur la classe, le sexe, le port d'embarquement et le type de famille, chacun filtrant l'ensemble de la page.

Page 2, Familles et âge. Le taux de survie par type de famille ventilé par sexe. Un histogramme des âges par tranche de cinq ans, coloré par statut (la tranche peut être construite dans Power Query ou en DAX ; le choix est à justifier dans les notes). Une matrice type de famille par classe donnant le nombre de passagers et le taux de survie, avec une mise en forme conditionnelle sur le taux. Un visuel de votre choix qui n'existe pas dans le tableau de bord du cours, accompagné d'une phrase dans les notes expliquant ce qu'il apporte.

Sur les deux pages : un titre, une mention de la source et du nombre de lignes, des libellés en français, une palette identique d'une page à l'autre (bleu #2a78d6, aqua #1baf7a, gris #898781 comme en cours). Régler les interactions pour qu'un clic sur une barre de la page Survie mette en surbrillance les autres visuels sans les filtrer.

Les notes de conception rappellent en une phrase la question à laquelle le rapport répond, donnent trois constats chiffrés lus dans les visuels, signalent un risque de mauvaise interprétation (par exemple le lien entre classe et type de famille) et indiquent ce qui a été traité dans Power Query plutôt qu'en DAX, et pourquoi.